



POLISH-JAPANESE ACADEMY
OF INFORMATION TECHNOLOGY

Wydział Informatyki

Katedra Systemów Inteligentnych i Data Science

Inteligentne systemy przetwarzania danych

Kamil Czyżewski
Nr albumu s22370

Jakub Szulc
Nr albumu s23640

Konfigurowalne środowisko AutoML dla finansowych potoków
predykcyjnych w turnieju Numerai

Praca magisterska

Promotor techniczny: Filip Dzięcioł

Promotor główny: Grzegorz Wójcik

Warszawa, sierpień 2026



**POLISH-JAPANESE ACADEMY
OF INFORMATION TECHNOLOGY**

Faculty of Computer Science

Department of Intelligent Systems and Data Science

Intelligent Data Processing Systems

Kamil Czyżewski

Student identification number s22370

Jakub Szulc

Student identification number s23640

Configurable AutoML Environment for Financial Prediction Pipelines in the Numerai Tournament

Master's thesis

Technical supervisor: Filip Dzięcioł

Main supervisor: Grzegorz Wójcik

Warsaw, August 2026

data, miejscowość

OŚWIADCZENIE STUDENTA DOTYCZĄCE WYKORZYSTANIA SZTUCZNEJ INTELIGENCJI (AI)

Ja, niżej podpisany/a: **Kamil Czyżewski**
student/ka kierunku: **Informatyka, specjalność Inteligentne systemy przetwarzania danych**
numer albumu studenta: **s22370**.

Oświadczam, że zapoznałem/am się z treścią Zarządzenia Rektora Polsko-Japońskiej Akademii Technik Komputerowych z dnia 1 kwietnia 2026 r. oraz z „Wytycznymi dotyczącymi wykorzystywania sztucznej inteligencji w procesie dydaktycznym PJATK”, stanowiącymi załącznik do ww. zarządzenia.

Oświadczam, że ewentualne wykorzystanie narzędzi sztucznej inteligencji (AI) w niniejszej pracy miało charakter wyłącznie pomocniczy i nie stanowiło zastępstwa dla mojej samodzielnej pracy.

Oświadczam, że treść pracy stanowi moje własne, samodzielne opracowanie oraz ponoszę pełną odpowiedzialność za jej zawartość, niezależnie od wykorzystania narzędzi AI.

Oświadczam, że nie wykorzystywałem/am narzędzi AI do generowania treści stanowiących zasadniczą część pracy, w szczególności analiz, wniosków, interpretacji ani części podlegających ocenie jako przejaw twórczości własnej.

W przypadku korzystania z narzędzi AI sporządziłem/am Raport użycia AI zgodnie z obowiązującymi Wytycznymi i dołączyłem/am go do pracy.

czytelny podpis studenta/studentki

data, miejscowość

OŚWIADCZENIE STUDENTA DOTYCZĄCE WYKORZYSTANIA SZTUCZNEJ INTELIGENCJI (AI)

Ja, niżej podpisany/a: **Jakub Szulc**
student/ka kierunku: **Informatyka, specjalność Inteligentne systemy przetwarzania danych**
numer albumu studenta: **s23640**.

Oświadczam, że zapoznałem/am się z treścią Zarządzenia Rektora Polsko-Japońskiej Akademii Technik Komputerowych z dnia 1 kwietnia 2026 r. oraz z „Wytycznymi dotyczącymi wykorzystywania sztucznej inteligencji w procesie dydaktycznym PJATK”, stanowiącymi załącznik do ww. zarządzenia.

Oświadczam, że ewentualne wykorzystanie narzędzi sztucznej inteligencji (AI) w niniejszej pracy miało charakter wyłącznie pomocniczy i nie stanowiło zastępstwa dla mojej samodzielnej pracy.

Oświadczam, że treść pracy stanowi moje własne, samodzielne opracowanie oraz ponoszę pełną odpowiedzialność za jej zawartość, niezależnie od wykorzystania narzędzi AI.

Oświadczam, że nie wykorzystywałem/am narzędzi AI do generowania treści stanowiących zasadniczą część pracy, w szczególności analiz, wniosków, interpretacji ani części podlegających ocenie jako przejaw twórczości własnej.

W przypadku korzystania z narzędzi AI sporządziłem/am Raport użycia AI zgodnie z obowiązującymi Wytycznymi i dołączyłem/am go do pracy.

czytelny podpis studenta/studentki

Abstrakt

Praca dotyczy projektowania i implementacji konfigurowalnego środowiska wspierającego tworzenie oraz ocenę potoków uczenia maszynowego dla danych finansowych o strukturze czasowej. Celem było połączenie przygotowania danych, konfigurowania eksperymentów, doboru modeli, automatycznego strojenia, walidacji i przygotowania rozwiązania do wdrożenia w jeden spójny proces. Opracowany system AlphaPulse umożliwia deklaratywne opisywanie eksperymentów, wymienne łączenie komponentów oraz ocenę modeli z uwzględnieniem kolejności czasowej danych.

System zweryfikowano w studium przypadku dotyczącym turnieju Numerai, obejmującym wykonanie pełnego potoku oraz porównanie kilku rodzin modeli. Analiza koncentruje się na wykonalności rozwiązania, jakości procesu walidacji i praktycznych ograniczeniach automatycznego doboru konfiguracji. Przeprowadzone eksperymenty wskazują, że rozwiązanie porządkuje cykl pracy i pozwala porównywać warianty w jednolity sposób. Wnioski podkreślają jednocześnie potrzebę ostrożnej interpretacji wyników dla danych finansowych oraz dalszej walidacji przed zastosowaniem produkcyjnym.

Słowa kluczowe: AutoML, uczenie maszynowe, dane finansowe, walidacja czasowa, potoki predykcyjne

Abstract

This thesis concerns the design and implementation of a configurable environment for building and evaluating machine-learning pipelines for financial data with a temporal structure. Its objective was to combine data preparation, experiment configuration, model selection, automated tuning, validation and deployment preparation into a coherent process. The resulting AlphaPulse system supports declarative experiment definitions, interchangeable components and model evaluation that respects the temporal ordering of observations.

The system was verified through a case study based on the Numerai tournament, covering an end-to-end pipeline and a comparison of several model families. The analysis focuses on the feasibility of the solution, the quality of the validation process and the practical limitations of automated configuration selection. The experiments indicate that the system structures the experimental workflow and allows variants to be compared consistently. The conclusions also emphasise the need for cautious interpretation of results obtained from financial data and for additional validation before production use.

Keywords: AutoML, machine learning, financial data, temporal validation, prediction pipelines

Spis treści

1	Wstęp	4
2	Podstawy problemu i kontekst systemu AlphaPulse	7
3	Architektura systemu AlphaPulse	11
4	Implementacja systemu AlphaPulse	15
5	Metodyka badań	21
6	Wyniki eksperymentów	29
7	Dyskusja i zakończenie	38
	Wykaz tabel	42
	Wykaz rysunków	43
	Bibliografia	44

Rozdział 1

Wstęp

1.1 Kontekst i motywacja

Prognozowanie rynków finansowych należy do szczególnie trudnych zastosowań uczenia maszynowego. Dane charakteryzują się niskim stosunkiem sygnału do szumu, niestacjonarnością oraz zależnościami czasowymi. W Numerai obserwacje są dodatkowo grupowane w ery, czyli przekroje rynku odpowiadające kolejnym okresom. Losowy podział na zbiór uczący i testowy nie odzwierciedla tej struktury i może prowadzić do zawyżonej oceny jakości. Ocena na późniejszych okresach ogranicza zależność wniosków od jednego podziału, lecz nie usuwa ryzyka przeuczenia procedury selekcji ani wpływu zmieniających się warunków rynkowych.¹

Numerai, działające od 2015 roku, udostępnia uczestnikom zanonimizowane dane tabelaryczne opisujące instrumenty finansowe za pomocą ukrytych cech. Zadaniem uczestników jest prognozowanie jednego z celów reprezentujących przyszły wynik instrumentu. W badaniu końcowym wykorzystano `target_ender_60`. Predykcje modeli objętych stakingiem są agregowane w ważony stawką Meta Model wykorzystywany przez fundusz Numerai. Staking jest opcjonalny, a dodatnie wyniki mogą zwiększyć liczbę NMR uczestnika, a ujemne prowadzą do spalenia części stawki.²

Prowadzi to do praktycznego problemu badawczego: jak systematycznie porównywać konfiguracje uczenia maszynowego, zachowując poprawną walidację czasową, oficjalne metryki oceny i wymagany format artefaktu predykcyjnego?

Ogólne systemy AutoML wspierają dobór modeli i hiperparametrów,³ lecz nie uwzględniają automatycznie wymagań właściwych dla Numerai: podziałów według er, separacji czasowej zależnej od horyzontu celu, oficjalnych metryk ani dwóch ścieżek wdrożenia. Zwykła submisja przekazuje wektor predykcji w CSV, natomiast opcjonalny Model Upload przyjmuje serializowaną funkcję `predict.pkl`.⁴ AlphaPulse integruje te elementy w jednym przepływie - od danych i konfiguracji po ocenę oraz artefakt końcowy.

¹D. H. Bailey i in. "The Probability of Backtest Overfitting". W: *Journal of Computational Finance* 20.4 (2017), 39-69; G. C. Cawley i N. L. C. Talbot. "On Over-Fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation". W: *Journal of Machine Learning Research* 11 (2010), 2079-2107.

²Numerai. *Staking - Numerai Tournament Documentation*. URL: <https://docs.numer.ai/numerai-tournament/staking> (term. wiz. 23.08.2026).

³X. He, K. Zhao i X. Chu. "AutoML: A Survey of the State-of-the-Art". W: *Knowledge-Based Systems* 212 (2021).

⁴Numerai. *Submissions - Numerai Tournament Documentation*. URL: <https://docs.numer.ai/numerai-tournament/submissions> (term. wiz. 30.08.2026); Numerai. *Model Uploads - Numerai Tournament Documentation*. URL: <https://docs.numer.ai/numerai-tournament/submissions/model-uploads> (term. wiz. 30.08.2026).

1.2 Problem badawczy

Praca odpowiada na następujące pytanie badawcze:

Jak zaprojektować, zaimplementować i zweryfikować środowisko, które umożliwia systematyczne i kontrolowane eksperymentowanie z potokami uczenia maszynowego dla danych finansowych turnieju Numerai?

Problem ten dekomponuje się na następujące pytania szczegółowe:

1. Jakie kontrakty komponentów są potrzebne, aby połączyć dane, przetwarzanie wstępne, modele, strategie zespołowe, ewaluację i eksport w jednym systemie.
2. Jak zakodować wymagania walidacji czasowej i spójności protokołu tak, aby kolejne konfiguracje były oceniane według tego samego protokołu.
3. Czy zaimplementowany potok wykonuje kompletny przebieg na pełnej skali danych i zapisuje konfigurację, wyniki oraz artefakty uruchomienia.
4. Jak w ustalonym budżecie zachowują się badane rodziny modeli oraz w jakim stopniu ranking z holdoutu przenosi się na późniejszy przedział czasowy.

1.3 Cele pracy

Głównym celem pracy jest zaprojektowanie i zaimplementowanie systemu AlphaPulse, który:

- ujednolica pełny przepływ pracy konkursu Numerai - od pobierania danych po eksport submisji,
- umożliwia deklaratywne definiowanie eksperymentów w formacie YAML, bez konieczności modyfikowania kodu źródłowego,
- implementuje walidację uwzględniającą strukturę er, separację czasową i embargo,
- automatyzuje poszukiwanie optymalnych hiperparametrów i konfiguracji potoku za pomocą Optuna (tryb `--local`) lub Ray Tune (tryb rozproszony), z obsługą `--resume` i bazą TrialDB,
- udostępnia rozszerzenie AutoResearch, w którym model językowy proponuje modyfikacje konfiguracji, bez przypisywania temu mechanizmowi przewagi empirycznej w badaniu końcowym,
- raportuje oficjalnie zdefiniowane CORR i MMC oraz ich agregaty dla poszczególnych er,
- eksportuje przenośną funkcję predykcyjną `predict.pkl` oraz wspiera tygodniowy cykl produkcyjny: inferencję na `live.parquet`, utworzenie pliku CSV i przesłanie predykcji przez API Numerai.

Celami pomocniczymi są: weryfikacja wykonalności kompletnego przepływu w pełnej skali, opisowe porównanie rodzin modeli w jednakowym protokole HPO, analiza zgodności rankingów na dwóch odległych przedziałach czasowych oraz wskazanie kandydatów reprezentujących kompromis CORR-MMC. Praca nie mierzy oszczędności czasu człowieka, przewagi AutoResearch ani przyczynowego wpływu pojedynczych komponentów.

1.4 Zakres i ograniczenia

Framework AlphaPulse jest przeznaczony dla turnieju Numerai Classic, a badanie końcowe wykorzystuje zestaw danych w wersji v5.3. Zakres pracy obejmuje:

- Modele tabelaryczne: wzmacnianie gradientowe, modele drzewiste, modele liniowe, modele typu foundation dla danych tabelarycznych (TabPFN, TabPFN3, TabICL) oraz uczenie głębokie (TabularDL z architekturami FT-Transformer i MLP).
- Preprocessors: skalowanie, redukcja wymiarowości, selekcja cech, autoenkoder, kompresja cech, selektor stabilności per-era (EraStableFeatureSelector) i regularyzacja poprzez szum gaussowski.
- Strategie ensemble: single, weighted, stacking, potoki wielogłowicowe (MultiHeadPipeline) i wielocelowe (MultiTargetPipeline).
- Optymalizację hiperparametrów (Optuna TPE w trybie lokalnym, Ray Tune w trybie rozproszonym) oraz system AutoResearch z agentem opartym na modelu językowym.
- Panel EDA (Streamlit) do eksploracji danych i wizualizacji wyników HPO.

Praca nie obejmuje: analizy modeli sekwencyjnych, czyli na przykład LSTM czy Transformer, dla danych czasowych, strategii tradingowych ani mechanizmów stakowania tokenów NMR, a także integracji z turniejem Numerai Signals.

1.5 Kryteria sukcesu

Cele techniczne pracy uznaje się za osiągnięte, jeśli:

1. środowisko utrzuła konfigurację, ziarna losowe i proveniencję uruchomienia,
2. HPO poprawnie realizuje próbkowanie, ocenę, persystencję i wznowienie prób.
3. mechanizm AutoResearch poprawnie proponuje mutacje oraz zapisuje stan umożliwiający wznowienie, przy czym jego skuteczność nie jest przedmiotem porównania empirycznego,
4. artefakt Model Upload przechodzi lokalną walidację formatu i test dymny (*export smoke test*) przed weryfikacją w oficjalnym środowisku,
5. seria eksperymentalna identyfikuje co najmniej jedną konfigurację o dodatnim CORR Sharpe na holdoucie i dodatnim MMC Sharpe na późniejszym przedziale selekcyjnym.

Rozdział 2

Podstawy problemu i kontekst systemu AlphaPulse

Rozdział przedstawia kontekst domenowy i techniczny, w którym powstał *AlphaPulse*: turniej Numerai, charakter danych, kryteria oceny modeli, ograniczenia metodologiczne oraz wymagania wobec AutoML dla finansowych potoków predykcyjnych.

2.1 Specyfika turnieju Numerai

Numerai jest konkursem data science, w którym uczestnicy budują modele predykcyjne na zanonimizowanych danych tabelarycznych i dostarczają predykcje do wspólnego meta-modelu funduszu. W przeciwieństwie do klasycznych konkursów ML liczy się jakość predykcji, ale też stabilność sygnału i odporność na zmianę warunków rynkowych.¹

Przekłada się to na kilka konsekwencji:

- dane mają strukturę czasową i grupową (ery),
- błędna walidacja może sztucznie zawyżać wyniki,
- spójne wykonanie eksperymentów ma realne znaczenie,
- końcowym artefaktem jest plik predykcji w wymaganym formacie submisji.

Takie środowisko premiuje podejście systemowe: powtarzalne potoki, kontrolę konfiguracji, jasne logowanie eksperymentów i automatyzację przeszukiwania przestrzeni modeli.

2.2 Charakterystyka danych finansowych

Dane używane w zadaniach Numerai to dane tabelaryczne z wyraźnym komponentem czasowym. Z perspektywy modelowania najważniejsze są:

- niski stosunek sygnału do szumu,
- niestacjonarność rozkładów cech i celu,
- zależności temporalne między obserwacjami,
- podatność na przeciek informacji przy niepoprawnym podziale danych.

Dlatego zarówno przetwarzanie wstępne, jak i procedura walidacyjna muszą być projektowane ostrożnie. Szczególnie ważne są metody uwzględniające strukturę er oraz separację czasową między zbiorem uczącym a walidacyjnym. Zmiana rozkładu między okresem uczenia i

¹Numerai. *Scoring - Numerai Tournament Documentation*. URL: <https://docs.numer.ai/numerai-tournament/scoring/> (term. wiz. 23. 08. 2026).

przyszłą oceną dodatkowo ogranicza możliwość przenoszenia wyników bez kontroli stabilności w czasie.²

2.3 Metryki jakości i kryteria oceny

W odróżnieniu od wielu zadań regresyjnych, ocena modeli finansowych nie powinna opierać się wyłącznie na błędzie punktowym. Dla każdej ery e oficjalny CORR porównuje predykcje $\hat{y}_e$ z celem y_e po transformacjach określonych w dokumentacji Numerai.³ Niech n_e oznacza liczbę obserwacji w erze, $R_e(v_i)$ rangę elementu v_i z zachowaniem remisów, a Φ^{-1} kwantyl standardowego rozkładu normalnego. Transformację predykcji można zapisać jako

$$z_e(v_i) = \Phi^{-1}\left(\frac{R_e(v_i) - \frac{1}{2}}{n_e}\right), \quad g(x) = \text{sgn}(x)|x|^{3/2}. \quad (2.1)$$

Oficjalny wynik CORR dla ery jest następnie korelacją Pearsona przekształconych wektorów:

$$c_e = \rho_P(g(y_e - \bar{y}_e), g(z_e(\hat{y}_e))). \quad (2.2)$$

MMC mierzy część sygnału predykcji, której nie wyjaśnia Meta Model. Dla $p_e = z_e(\hat{y}_e)$ oraz znormalizowanej predykcji Meta Modelu $b_e = z_e(b_e^{\text{raw}})$ neutralizacja jest rzutem na dopełnienie ortogonalne wektora b_e :

$$p_e^\perp = p_e - b_e \frac{p_e^\top b_e}{b_e^\top b_e}. \quad (2.3)$$

Dla celu Numerai zapisanego w przedziale $[0, 1]$ wynik wkładu w erze ma postać

$$m_e = \frac{1}{n_e} (4y_e - \overline{4y_e})^\top p_e^\perp. \quad (2.4)$$

Definicja odpowiada funkcji `correlation_contribution` z zamrożonej wersji `numerai-tools 0.6.0`.⁴

Stabilność obu miar agreguje współczynnik Sharpe’a liczony po erach:

$$S_{\text{CORR}} = \frac{\bar{c}}{s_c}, \quad S_{\text{MMC}} = \frac{\bar{m}}{s_m}, \quad (2.5)$$

gdzie $c = (c_1, \dots, c_E)$ i $m = (m_1, \dots, m_E)$, a s_c i s_m są odchyleniami standardowymi między erami. AlphaPulse raportuje także:

²M. Sugiyama, M. Krauledat i K.-R. Müller. “Covariate Shift Adaptation by Importance Weighted Cross Validation”. W: *Journal of Machine Learning Research* 8 (2007), 985-1005.

³Numerai. *Correlation (CORR) - Numerai Tournament Documentation*. URL: <https://docs.numer.ai/numerai-tournament/scoring/correlation-corr> (term. wiz. 23. 08. 2026).

⁴Numerai. *Meta Model Contribution (MMC) - Numerai Tournament Documentation*. URL: <https://docs.numer.ai/numerai-tournament/scoring/meta-model-contribution-mmc> (term. wiz. 23. 08. 2026); Numerai. *numerai-tools 0.6.0*. Python Package Index. 10 czer. 2026. URL: <https://pypi.org/project/numerai-tools/0.6.0/> (term. wiz. 23. 08. 2026).

- średni CORR i odchylenie standardowe między erami,
- udział er z dodatnim CORR oraz maksymalne obsunięcie skumulowanego CORR,
- średni MMC, jego odchylenie standardowe i S_{MMC} .

Implementacje zweryfikowano względem tej samej zamrożonej wersji biblioteki. W badaniu głównym kryterium optymalizacji stanowi S_{CORR} na holdoutcie oddzielnym strefą purge. CORR i MMC na późniejszym przedziale selekcyjnym służą do analizy transferu w czasie oraz wyboru kompromisu między siłą i unikalnością sygnału. Ponieważ ten drugi przedział uczestniczy w wyborze kandydatów, raportowane na nim wartości nie są bezstronnym oszacowaniem przyszłego wyniku produkcyjnego.⁵

2.4 Ryzyko wycieku informacji i poprawna walidacja

W modelach finansowych jednym z najpoważniejszych problemów jest *look-ahead bias*: niejawnie użycie informacji, której w momencie predykcji jeszcze by nie było. Może pojawić się na wielu etapach:

- podczas przygotowania cech,
- przy podziale danych na train/validation,
- przy doborze hiperparametrów.

Dlatego system klasy *AlphaPulse* musi wspierać walidację zgodną z naturą danych czasowych i erowych, w tym podejścia *era-aware* oraz *purged cross-validation*. Wymóg ten stanowi fundament wiarygodnej oceny i bezpośrednio wpływa na konstrukcję architektury systemu.⁶ Sama separacja czasowa nie usuwa jednak błędu selekcyjnego. Wielokrotna optymalizacja na tym samym holdoutcie może dopasować konfigurację do szumu kryterium, dlatego wynik wybranej próby należy interpretować warunkowo względem całej procedury wyszukiwania.⁷

2.5 AutoML, HPO i modele tabelaryczne

Systemy AutoML automatyzują dobór algorytmu, transformacji i hiperparametrów, ale ich skuteczność zależy od poprawnej definicji przestrzeni poszukiwań, budżetu i protokołu walidacji.⁸ Losowe wyszukiwanie stanowi naturalny punkt odniesienia dla metod adaptacyjnych, ponieważ efektywny wymiar przestrzeni hiperparametrów bywa znacznie mniejszy od jej wy-

⁵Cawley i Talbot, patrz uw. 1; S. Varma i R. Simon. "Bias in Error Estimation When Using Cross-Validation for Model Selection". W: *BMC Bioinformatics* 7.91 (2006).

⁶M. López de Prado. *Advances in Financial Machine Learning*. Wiley, 2018; C. Bergmeir, R. J. Hyndman i B. Koo. "A Note on the Validity of Cross-Validation for Evaluating Autoregressive Time Series Prediction". W: *Computational Statistics and Data Analysis* 120 (2018), 70-83.

⁷Cawley i Talbot, patrz uw. 1; Bailey i in., patrz uw. 1.

⁸He, Zhao i Chu, patrz uw. 3; M. Feurer i in. "Efficient and Robust Automated Machine Learning". W: *Advances in Neural Information Processing Systems*. T. 28. 2015; L. Kotthoff i in. "Auto-WEKA 2.0: Automatic Model Selection and Hyperparameter Optimization in WEKA". W: *Journal of Machine Learning Research* 18.25 (2017), 1-5.

miaru nominalnego.⁹ AlphaPulse wykorzystuje Optuna TPE do sekwencyjnego wyboru prób oraz Ray Tune do wykonania rozproszonego.¹⁰ Warstwa optymalizacji nie zastępuje metodyki badawczej: każda konfiguracja przechodzi ten sam podział czasowy, ten sam scoring i zapis proveniencji.

Przestrzeń modeli obejmuje algorytmy wzmacniania gradientowego - XGBoost, LightGBM i CatBoost - które pozostają silnymi punktami odniesienia dla danych tabelarycznych.¹¹ Uzupełniają je modele liniowe, zespoły drzew oraz modele typu foundation dla danych tabelarycznych, w tym TabPFN i TabICL.¹² Z perspektywy badawczej ważna jest wspólna abstrakcja modelu: umożliwia porównanie rodzin w jednym protokole, bez wiązania warstwy danych i ewaluacji z konkretną biblioteką.

2.6 Luka projektowa i rola AlphaPulse

Na potrzeby pracy lukę projektową zdefiniowano jako brak spójnego przepływu, który łączy cztery wymagania eksperymentów dla Numerai: deklaratywną konfigurację potoku, walidację respektującą kolejność er, ocenę za pomocą oficjalnych metryk oraz przygotowanie artefaktu do inferencji. Realizacja tych etapów oddzielnymi skryptami utrudnia zachowanie jednego protokołu i powiązanie wyniku z konfiguracją, wersją kodu oraz danymi wejściowymi.

AlphaPulse odpowiada na tę lukę przez podejście sterowane konfiguracją. Opis eksperymentu jest oddzielony od mechaniki wykonania, dzięki czemu ten sam graf potoku może zostać uruchomiony w trybie pojedynczym, HPO, diagnostycznym i eksportowym. System utrzuca konfigurację, parametry oraz proveniencję uruchomienia, co umożliwia spójne porównywanie wyników.

Zakres przepływu obejmuje dane i konfigurację YAML, trening, HPO, walidację erową oraz eksport funkcji `predict.pkl` lub pliku CSV. W dalszej części AlphaPulse jest zatem traktowany jako środowisko do budowy i oceny potoków, a nie jako pojedynczy model.

⁹J. Bergstra i Y. Bengio. “Random Search for Hyper-Parameter Optimization”. W: *Journal of Machine Learning Research* 13 (2012), 281-305.

¹⁰T. Akiba i in. “Optuna: A Next-generation Hyperparameter Optimization Framework”. W: *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2019; R. Liaw i in. “Tune: A Research Platform for Distributed Model Selection and Training”. W: *arXiv preprint arXiv:1807.05118* (2018).

¹¹T. Chen i C. Guestrin. “XGBoost: A Scalable Tree Boosting System”. W: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016; G. Ke i in. “LightGBM: A Highly Efficient Gradient Boosting Decision Tree”. W: *Advances in Neural Information Processing Systems*. 2017; L. Prokhorenkova i in. “CatBoost: Unbiased Boosting with Categorical Features”. W: *Advances in Neural Information Processing Systems*. 2018; L. Grinsztajn, E. Oyallon i G. Varoquaux. “Why Do Tree-Based Models Still Outperform Deep Learning on Typical Tabular Data?”. W: *Advances in Neural Information Processing Systems*. T. 35. 2022.

¹²N. Hollmann i in. “Accurate Predictions on Small Data with a Tabular Foundation Model”. W: *Nature* 637 (2025), 319-326; J. Qu i in. “TabICL: A Tabular Foundation Model for In-Context Learning on Large Data”. W: *Proceedings of the 42nd International Conference on Machine Learning*. 2025. arXiv: 2502.05564.

Rozdział 3

Architektura systemu AlphaPulse

Celem rozdziału jest przedstawienie architektury *AlphaPulse* jako konfigurowalnego systemu AutoML dla danych finansowych Numerai. Opis obejmuje warstwy systemu, przepływ danych, komponenty wykonawcze oraz mechanizmy wspierające spójność i iteracyjny rozwój eksperymentów.

3.1 Założenia architektoniczne

AlphaPulse opiera się na kilku założeniach:

- **Konfigurowalność:** eksperymenty są definiowane deklaratywnie, bez każdorazowej modyfikacji kodu źródłowego,
- **Modularność:** preprocessing, modele i strategie ensemble są odseparowane i mogą być dowolnie komponowane,
- **Powtarzalność:** konfiguracja, kontrolowane ziarna i proveniencja ograniczają niezamierzoną zmienność, ale nie gwarantują identyczności bitowej między sprzętem, sterownikami i wersjami bibliotek,
- **Rozszerzalność:** nowe komponenty mogą być dodawane bez naruszania istniejącego przepływu,
- **Automatyzacja:** architektura wspiera zarówno klasyczne eksperymenty, jak i zautomatyzowane przeszukiwanie konfiguracji (HPO, AutoResearch).

3.2 Widok warstwowy systemu

Architekturę systemu można opisać jako układ pięciu współpracujących warstw.

3.2.1 Warstwa danych

Warstwa danych odpowiada za:

- pobranie i lokalne utrzymanie zbiorów Numerai,
- ładowanie podziałów (np. train/validation),
- przygotowanie macierzy cech, celu i metadanych (era),
- kontrolę parametrów wejściowych (np. próbkowanie podzbioru, zestaw cech).

Ta warstwa dostarcza ustandaryzowany interfejs wejściowy dla całego potoku.

3.2.2 Warstwa konfiguracji eksperymentu

Konfiguracja eksperymentu jest deklarowana w formacie YAML i walidowana względem schematu. Opisuje m.in.:

- źródło danych i parametry podziału,
- zestawy cech i grupy cech,
- listę preprocessingu,
- typy modeli oraz ich hiperparametry,
- strategię ensemble,
- parametry treningu i ewaluacji.

Dzięki temu logika eksperymentu jest jawna i łatwa do wersjonowania.

3.2.3 Warstwa potoku modelowego

Warstwa potoku realizuje sekwencję: `Data` → `Preprocessing` → `Model(e)` → `Ensemble` → `Prediction`. W ramach tej warstwy:

- preprocessory przekształcają cechy wejściowe,
- modele bazowe uczą się predykcji celu,
- ensemble agreguje sygnały modeli cząstkowych.

Potok jest budowany dynamicznie na podstawie konfiguracji, co umożliwia szybkie porównywanie wielu wariantów architektury modelowej.

3.2.4 Warstwa optymalizacji i automatyzacji

System wspiera dwa poziomy automatyzacji:

- **HPO**: przeszukiwanie przestrzeni hiperparametrów i konfiguracji komponentów z użyciem Optuna TPE (flaga `--local`) lub Ray Tune (tryb domyślny rozproszony). Każda próba działa w izolowanym podprocesie, a stan prób jest persystowany w SQLite (TrialDB), co umożliwia wznowienie przerwanej serii (`--resume`). Głównym celem optymalizacji w badaniu jest oficjalny numerai_corr_sharpe. Raport obejmuje także średni CORR, maksymalne obsunięcie, udział dodatnich er oraz MMC na późniejszym przedziale czasowym,
- **AutoResearch**: agentowa pętla badawcza, która proponuje mutacje konfiguracji (dodanie lub usunięcie modelu, zmianę preprocessingu, ensemble albo neutralizację) i ocenia ich wpływ na metryki.

Wynikiem działania tej warstwy jest ranking prób, najlepsza konfiguracja (`best_config.json`), historia decyzji eksperymentalnych oraz diagnostyka w Weights & Biases.

3.2.5 Warstwa ewaluacji i diagnostyki

Warstwa ewaluacji obejmuje:

- **Backtester** i **EraSplitEvaluator** z opcjonalną neutralizacją cech (`FeatureNeutralizer`) przed obliczeniem metryk,
- walidację krzyżową *PurgedEraCV* oraz walk-forward z *purge/embargo*,
- raporty SHAP (`shap_report.py`) i ważności cech per-era,
- logowanie wykresów diagnostycznych do W&B (`wandb_diagnostics.py`): korelacja per-era, ekspozycja cech, mapa cieplna korelacji zespołu, zbieżność HPO.

3.2.6 Warstwa artefaktów i eksportu


Warstwa artefaktów odpowiada za:

- zapisy metryk i logów eksperymentów,
- serializację najlepszych konfiguracji,
- eksport wytrenowanego potoku jako funkcji `predict.pkl` dla Model Upload oraz zapis predykcji jako CSV (kolumny `id` i `prediction`).

W ten sposób przepływ prowadzi od eksperymentu badawczego do artefaktu konkursowego.

3.3 Diagram architektury logicznej

Rysunek 3.1: Diagram architektury systemu AlphaPulse. Przedstawia warstwę danych, konfigurację eksperymentów, potok predykcyjny, walidację, eksport oraz panel EDA.



Źródło: opracowanie własne.

Diagram przedstawia pięć warstw rozdzielających dane, konfigurację, modelowanie, walidację i eksport. Kolejny rozdział opisuje ich implementację.

Rozdział 4

Implementacja systemu AlphaPulse

Rozdział przedstawia implementację *AlphaPulse*: organizację kodu, konfigurację eksperymentów, CLI oraz przebieg potoku od danych do artefaktu submisyjnego.

4.1 Organizacja repozytorium

Implementacja projektu została podzielona na warstwy odpowiadające cyklowi pracy eksperymentalnej:

- `src/alphapulse/` - kod domenowy: potok, HPO, ewaluacja, AutoResearch i moduł cech,
- `scripts/` - skrypty wykonawcze CLI dla najważniejszych scenariuszy,
- `experiments/` - deklaratywne definicje eksperymentów (YAML),
- `eda/` - samodzielny panel Streamlit do analizy eksploracyjnej,
- `tests/` - testy jednostkowe i integracyjne (w tym metryki MMC),
- `artifacts/` - wyniki uruchomień, konfiguracje i eksporty.

Taki podział rozdziela logikę systemu od warstwy operacyjnej (uruchamianie), co zwiększa czytelność i ułatwia utrzymanie projektu.

4.2 Warstwa uruchomieniowa (CLI)

4.2.1 Skrypty wykonawcze

System udostępnia zestaw skryptów CLI obsługujących pełny przepływ:

- `download_dataset.py` - pobieranie danych Numerai,
- `run_experiment.py` - uruchamianie eksperymentów YAML, opcjonalnie z projektem W&B,
- `hpo_pipeline.py` - HPO (Optuna lokalnie lub Ray Tune),
- `autoresearch.py` - pętla agentowa AutoResearch,
- `run_test_pipeline.py` - lekki test pełnego przepływu,
- `export_numerai_pickle.py`, `export_from_yaml.py` - eksport `predict.pkl`,
- `live_inference.py` - predykcje na `live.parquet`,
- `submit_predictions.py` - przesyłanie predykcji do API Numerai,
- `make_feature_groups.py` - generowanie grup cech z `features.json`.

Skrypty pełnią rolę cienkiej warstwy orkiestracji: pobierają argumenty, walidują wejście, inicjują komponenty systemu i zapisują artefakty.

4.2.2 Konwencja parametrów wejściowych

Interfejs CLI wykorzystuje jednolitą konwencję argumentów:

- ścieżki danych i artefaktów (`--data-dir`, `--output-dir`),
- parametry skali eksperymentu (`--train-subsample`, liczba prób),
- wskazanie konfiguracji źródłowej (`--config`, `--best-config-path`),
- tryb lokalny lub rozproszony (zależnie od skryptu).

Ujednolicenie argumentów upraszcza automatyzację i integrację z narzędziami CI/CD.

4.3 Konfiguracja eksperymentów (YAML)

4.3.1 Schemat i walidacja

Eksperymenty definiowane są deklaratywnie. Schemat obejmuje sekcje:

- `data`,
- `features`,
- `preprocessing`,
- `models`,
- `ensemble_method/ensemble_params`,
- `train`,
- `evaluation`.

Każde uruchomienie przechodzi walidację zgodności konfiguracji, co ogranicza liczbę błędów wykonania i gwarantuje spójność eksperymentów.

4.3.2 Konfigurowalność bez zmian kodu

Najważniejszą własnością implementacji jest możliwość modyfikacji eksperymentu poprzez edycję YAML:

- zmiana modelu i hiperparametrów,
- podmiana preprocessingu,
- przełączenie strategii ensemble,
- zmiana metryki głównej ewaluacji.

Pozwala to prowadzić szybkie iteracje przy zachowaniu kontroli wersji zmian w repozytorium.

4.4 Implementacja warstwy danych

4.4.1 Loader danych Numerai

Warstwa danych dostarcza zunifikowany interfejs ładowania podziałów oraz metadanych. Implementacja obejmuje:

- odczyt plików parquet i plików opisowych,
- wybór zestawu cech i próbkowania podzbioru,
- przygotowanie struktur X , y , era .

Taki kontrakt danych jest wykorzystywany przez wszystkie wyższe warstwy potoku.

4.4.2 Obsługa danych wejściowych pod eksperymenty

Loader obsługuje zarówno pełne zbiory, jak i tryby szybkich testów na podzbiorach danych. To umożliwia:

- szybkie cykle rozwoju,
- tańsze testy poprawności potoku,
- stopniowe skalowanie kosztownych eksperymentów.

4.5 Panel analizy eksploracyjnej

Panel EDA jest osobną aplikacją Streamlit, która korzysta z tego samego loadera co potok eksperymentalny. Użytkownik wybiera wersję zbioru, zestaw cech i cel, a aplikacja ładuje właściwe kolumny z plików Parquet. Widoki obejmują strukturę zbioru, rozkłady i braki danych, korelacje, grupowanie cech, zmiany między erami oraz wyniki HPO. Panel wykorzystano do kontroli danych przed doбором podziału czasowego i przestrzeni konfiguracji opisanej w kolejnym rozdziale.

4.6 Implementacja potoku modelowego

4.6.1 Przetwarzanie wstępne

Implementacja przetwarzania wstępnego wykorzystuje listę kroków konfigurowanych w YAML. Wspierane są m.in.:

- skalowanie (*StandardScaler*, *RobustScaler*),
- redukcja wymiarowości (*PCA*, *TruncatedSVD*),
- selekcja cech i transformacje regularizujące.

Kroki przetwarzania wstępnego mogą być łączone w sekwencje, a komponenty stochastyczne otrzymują kontrolowane ziarna, o ile udostępnia je używana biblioteka.

4.6.2 Modele bazowe

Warstwa modeli została zaprojektowana jako zestaw wymiennych adapterów (spójny interfejs *fit/predict*) dla różnych rodzin:

- wzmacnianie gradientowe,
- modele drzewiaste,
- modele liniowe,
- wybrane modele typu foundation dla danych tabelarycznych.

Standaryzacja interfejsu upraszcza porównywanie modeli i ich integrację w zespoły. Modele drzewiaste są domyślnie opakowywane w `EraEnsembleModel`. Komponent dzieli ery uczące na rozłączne partycje, trenuje osobny estymator bazowy na każdej z nich, a następnie dopasowuje model Ridge do ich predykcji na wydzielonym wewnętrznym przedziale. Parametr `n_subs` oznacza zatem liczbę estymatorów bazowych, a nie liczbę modeli na poziomie całego potoku. Etykiety wewnętrznego przedziału są zarezerwowane dla Ridge. Modele bazowe wykorzystują stałą liczbę rund określoną w konfiguracji próby.

4.6.3 Strategie zespołowe

Implementacja obsługuje trzy podstawowe tryby:

- `single` - pojedynczy model,
- `weighted` - ważona agregacja predykcji,
- `stacking` - meta-model uczony na predykcjach bazowych.¹

Strategia zespołowa jest traktowana jako pełnoprawny element konfiguracji eksperymentu.

4.7 Implementacja HPO

4.7.1 Silniki optymalizacji

HPO realizowane jest przez moduł `src/alphapulse/hpo/` z dwoma trybami uruchomienia:

- **Tryb lokalny** (`--local`): Optuna TPE² (bayesowski mechanizm próbkowania) z izolacją każdej próby w osobnym podprocesie oraz bazy `optuna.db` i `trials.db` (TrialDB),
- **Tryb rozproszony**: Ray Tune³ z integracją W&B wymaga zainstalowania opcjonalnego zestawu zależności HPO.

Wspólne elementy obu trybów:

¹D. H. Wolpert. "Stacked Generalization". W: *Neural Networks* 5.2 (1992), 241-259.

²Akiba i in., patrz uw. 10.

³Liaw i in., patrz uw. 10.

- definicja przestrzeni przeszukiwania (`search_space.py`, `registry.py`),
- funkcja celu (`objective.py`) z oceną na przedziale erowym lub trzykrotną walidacją kroczącą,
- kierowanie cech (`feature_routing.py`) i strategię wielocelowe (`target_strategy.py`),
- limit czasu próby (`--trial-timeout`, domyślnie 3600 s) i budżet godzinowy (`--max-hours`),
- eksport najlepszej konfiguracji (`hpo/export.py`).

4.7.2 Śledzenie wyników prób

Każda próba zapisuje konfigurację, czas wykonania i oficjalne metryki `numera_i_corr_*` oraz `numera_i_mmc_*`. TrialDB przechowuje stan przeszukiwania, a opcjonalna integracja W&B udostępnia porównania przebiegów i diagnostyki modeli.

4.8 Implementacja AutoResearch

4.8.1 Pętla agentowa

AutoResearch rozszerza klasyczny HPO o mechanizm agentowy:

1. analiza dotychczasowych wyników,
2. propozycja mutacji konfiguracji,
3. uruchomienie kolejnej próby,
4. aktualizacja stanu badania.

Stan eksperymentu i decyzje agenta są zapisywane w artefaktach, co pozwala śledzić przebieg procesu.

4.8.2 Rola AutoResearch w implementacji

Mechanizm ten nie zastępuje pełni pracy badacza, lecz automatyzuje najbardziej powtarzalny etap: generowanie kolejnych hipotez konfiguracyjnych i ich testowanie. Wpływ tej automatyzacji na czas pracy wymaga kontrolowanego pomiaru i nie jest rozstrzygany na podstawie samej implementacji.

4.9 Eksport modelu i artefakty końcowe

Jedną ze ścieżek wdrożenia jest produkcja serializowanej funkcji dla Model Upload:

- odtworzenie najlepszego potoku z `best_config.json` lub YAML,
- trening na wskazanym zbiorze z zachowaniem kontraktu schematu cech,
- wygenerowanie predykcji z normalizacją rangową per-era,
- serializacja do `predict.pkl` z nazwą kanoniczną `<TIMESTAMP>_<ARCH>_<TARGET>_<CONFIG_HASH>_predict.pkl` oraz atomowo aktualizowaną kopią `latest_predict.pkl`,
- zapis `*_provenance.json` z konfiguracją i informacjami o środowisku uruchomienia,
- lokalny test dymny: czysty podproces łąduje plik i wykonuje predykcję na syntetycznej ramce danych, co nie zastępuje weryfikacji w oficjalnym środowisku Model Upload.

Alternatywna ścieżka submisji plikowej najpierw uruchamia inferencję na danych bieżącej rundy, a następnie zapisuje CSV z kolumnami `id` i `prediction`. Obie ścieżki zachowują wspólny kontrakt danych wejściowych i formatu predykcji.⁴

4.9.1 Przepływ produkcyjny (inferencja i submisja)

Tygodniowy cykl turniejowy realizowany jest trzema krokami:

1. pobranie świeżych danych (`live.parquet`),
2. `live_inference.py` - predykcje z walidacją formatu (`--validate`),
3. `submit_predictions.py` - przesłanie CSV (`id`, `prediction`) do API Numerai.

Skrypty wymagają kluczy `NUMERAI_PUBLIC_API_KEY` i `NUMERAI_PRIVATE_API_KEY` (lokalny plik `.env` lub zmienne środowiskowe).

4.10 Zapewnienie jakości kodu

Jakość implementacji jest kontrolowana przez formatowanie i linting w Ruff, statyczne sprawdzanie typów w mypy, testy w pytest oraz wykrywanie martwego kodu w Vulture. Wspólny cel `makecheck` uruchamia te kontrole przed zatwierdzeniem zmian w repozytorium.

⁴Numerai, *Submissions - Numerai Tournament Documentation*, patrz uw. 4; Numerai, *Model Uploads - Numerai Tournament Documentation*, patrz uw. 4.

Rozdział 5

Metodyka badań

Rozdział opisuje wykonane serie eksperymentalne, reguły włączenia obserwacji do analizy oraz sposób wyboru kandydatów. Rozdzielono dwa rodzaje wyników: weryfikację działania całego systemu na pełnej skali oraz porównanie jakości konfiguracji w jednolitym protokole Numerai v5.3.

5.1 Pytania eksperymentalne

Analiza odpowiada na pięć pytań:

1. Czy AlphaPulse wykonuje kompletny potok na pełnym zbiorze danych i zapisuje konfigurację, wyniki oraz artefakty wykonania.
2. Które rodziny modeli osiągają najwyższy oficjalny CORR Sharpe w ustalonym budżecie i podziale czasowym.
3. Jak zgodne są rankingi na holdoutcie oddzielnym strefą purge i późniejszym przedziale selekcyjnym oraz które konfiguracje tworzą kompromis CORR-MMC.
4. Jaki koszt wykonania i poziom kompletności prób uzyskano w serii HPO.
5. Jak wrażliwe jest maksimum holdoutowego CORR Sharpe na hipotetyczne zwiększenie liczby kompletnych prób przy jawnych założeniach scenariuszowych.

Porównania rodzin mają charakter opisowy. Próbkowanie obejmowało 20 ukończonych propozycji startowych i siedem adaptacyjnych, co dało nierówne liczebności grup. Obserwowane różnice nie są traktowane jako kontrolowana ablacja ani dowód przyczynowy.

5.2 Analiza eksploracyjna zbioru v5.3

Analizę wykonano na pełnym pliku `train.parquet` w wersji v5.3. Zbiór zawiera 2 746 268 wierszy przypisanych do 574 kolejnych er. Liczebność pojedynczej ery wynosi od 2314 do 6009 obserwacji, a mediana to 4923. Współczynnik zmienności liczebności er wynosi 15,7%. Różnice te nie są duże, ale sprawiają, że losowy podział wierszy nadawałby liczniejszym okresom większy wpływ i mieszał obserwacje z różnych momentów. Z tego powodu wszystkie późniejsze podziały są wykonywane według całych er.

Metadane pliku wskazują 3555 kolumn cech i brak wartości pustych w tych kolumnach. Cechy są zanonimizowane, dlatego nie można interpretować ich ekonomicznie na podstawie nazw. W badanym zestawie `small`, obejmującym 42 cechy, każda kolumna przyjmuje pięć uporządkowanych wartości od 0 do 4. Średnia celu `target_ender_60` wynosi 0,49995, a jego odchylenie standardowe 0,22369. Średnie celu w poszczególnych erach mieszczą się w bardzo wąskim za-

kresie od 0,49989 do 0,49996. Tak stabilny poziom wynika ze sposobu przygotowania danych i nie oznacza stabilności relacji predykcyjnych.

Tabela 5.1: Podsumowanie analizy eksploracyjnej pełnego zbioru treningowego v5.3

Właściwość	Wynik
Rozmiar i struktura czasowa	2 746 268 wierszy, 574 ery
Liczebność ery	2314-6009, mediana 4923
Kolumny cech i wartości puste	3555 cech, brak wartości pustych
Bezwzględna korelacja cecha-cel w zestawie small	mediana 0,00532, maksimum 0,01092
Bezwzględna korelacja między cechami w zestawie small	mediana 0,01570, percentyl 95: 0,24359, maksimum 0,73909


Źródło: opracowanie własne.

Na pełnym zbiorze pojedyncze cechy z zestawu small są tylko słabo skorelowane z celem. Mediana wartości bezwzględnej korelacji Pearsona wynosi 0,00532, a największa zaobserwowana wartość 0,01092. Wynik jest zgodny z niskim stosunkiem sygnału do szumu typowym dla tego zadania. Nie oznacza jednak, że cechy są wymienne. Dla korelacji między parami cech mediana wynosi 0,01570, lecz percentyl 95 osiąga 0,24359, a maksimum 0,73909. W zbiorze występują więc zarówno niemal niezależne kolumny, jak i wyraźnie powiązane grupy. Uzasadnia to dostępne w systemie kierowanie grup cech, redukcję wymiarowości i selekcję wariancji.

Analiza w obrębie er pokazuje bardziej zmienny obraz niż współczynnik policzony na wszystkich wierszach. Mediana bezwzględnej korelacji cecha-cel dla pary cecha-era wynosi 0,00850, percentyl 95 osiąga 0,02760, a największa wartość 0,05626. Dla typowej cechy ten sam znak korelacji utrzymuje się w 64,7% er. Oznacza to, że słaby sygnał nie tylko ma małą wartość, ale także zmienia się w czasie. Stabilny rozkład pojedynczych kolumn nie wystarcza zatem do uznania modelu za stabilny. Potrzebna jest ocena predykcji w kolejnych erach, separacja czasowa i agregacja metryk między okresami. Te obserwacje bezpośrednio uzasadniają przyjęty protokół walidacji oraz funkcje panelu EDA służące do analizy erowej, korelacji i grup cech.

Rysunek 5.1: Struktura er, stabilność średniej celu oraz korelacje dla 42 cech zestawu `small`.
Obliczenia wykonano na pełnym zbiorze treningowym `v5.3`.

Analiza eksploracyjna zbioru treningowego `Numerai v5.3`



Źródło: opracowanie własne.

5.3 Dwie serie o rozłącznych rolach

Materiał empiryczny obejmuje benchmark pełnoskalowy i końcową serię HPO (tabela 5.2). Różne wersje danych i cele wykluczają wspólny ranking jakości. Pierwsza seria odpowiada na pytanie o wykonalność i czas pełnej ścieżki, druga - o jakość konfiguracji według oficjalnych metryk.

Tabela 5.2: Serie wykorzystane w badaniu i ich role

Seria	Dane	Cel	Zakres train	Rola
Benchmark pełnoskalowy	v5.2	target	2 746 268 wierszy, 780 cech	wykonalność na pełnym zbiorze i kompletność przepływu
Końcowe HPO	v5.3	target_ender_60	274 627 wierszy, 256-989 unikalnych cech kierowanych przed przetwarzaniem wstępnym	porównanie oficjalnego CORR i MMC

Źródło: opracowanie własne.

Benchmark wykorzystał wszystkie 574 ery uczące. Potok StandardScaler oraz EraEnsemble z dziesięcioma modelami XGBoost przetworzył następnie 3 895 460 wierszy walidacyjnych w 1888,6 s, czyli 31,5 min. Wynik ten dokumentuje możliwość pracy na pełnej skali. Jego miary jakości nie są przenoszone do rankingu v5.3.

5.4 Dane i podział czasowy badania końcowego

Końcowe HPO korzysta z deterministycznej, dziesięcioprocentowej próby zbioru `train.parquet`: 274 627 wierszy i 574 ery. Plik źródłowy zawiera 3555 zanonimizowanych cech. Konfiguracja każdej próby wybierała grupy cech i łączyła je w zbiór zawierający od 256 do 989 unikalnych cech przed przetwarzaniem wstępnym. Transformacje grupowe mogły później zmienić wymiar. Przykładowo próba 22 wykorzystywała 989 cech, ale selektor wariancji pozostawiał 876 kolumn wyjściowych. Liczba 780 w protokole odpowiada domyślnemu zestawowi `medium`, a nie wspólnemu wymiarowi prób. Losowanie wierszy ma stałe ziarno 20260824, a integralność wejścia jest utrwalona skrótami SHA-256 w pliku `protocol.json`. Ziarno estymatora zmienia się deterministycznie między próbami i wynosi $20260824 + \text{numer próby}$. Każda próba przewiduje `target_ender_60`.


Ostatnie 52 ery próbki tworzą holdout. Szesnaście bezpośrednio poprzedzających er zostaje usuniętych z uczenia ze względu na nakładający się horyzont celu. W efekcie część ucząca obejmuje 506 er i 238 769 wierszy, strefa separacji 7814 wierszy, a holdout 28 044 wiersze.

Spośród 506 er przekazanych do modelowania końcowe 50 er przeznaczano na dopasowanie meta-modelu Ridge, a pozostałe 456 er służyło do uczenia modeli bazowych.

Drugim punktem oceny jest deterministyczna, dziesięcioprocentowa próba późniejszego fragmentu `validation.parquet`: 58 263 wiersze z er 1133-1220, dla których dostępna jest wyrównana predykcja Meta Modelu. Między erą 0574, kończącą źródłowy zbiór `train.parquet`, a erą 1133 pozostaje 558 er nieobjętych analizą. Późniejszy przedział nie jest więc oknem bezpośrednio następującym po holdoutcie. Umożliwia on obliczenie zarówno CORR, jak i MMC i nie steruje samplerem TPE, lecz uczestniczy w wyborze kandydatów końcowych, dlatego w dalszej części jest nazywany późniejszym przedziałem selekcyjnym, a nie zbiorem testowym.

Rysunek 5.2: Podział czasowy badania końcowego. Strefa 16 er oddziela uczenie od holdoutu, natomiast późniejszy przedział 88 er służy do analizy transferu, wyboru kandydatów oraz oceny MMC.

Próba ucząca v5.3: 274 627 wierszy, 574 ery · routing 256-989 z 3555 cech



Źródło: opracowanie własne.

5.5 Protokół HPO

Parametry protokołu zostały zapisane przed serią i nie zmieniały się między próbami. Najważniejsze ustawienia przedstawia tabela 5.3.

Do analizy włączono wyłącznie rekordy ze statusem `completed`, kompletną konfiguracją i pełnym zestawem trzech miar: CORR Sharpe na holdoutcie, CORR Sharpe na późniejszym przedziale oraz MMC Sharpe na tym przedziale. Nie wykonywano powtórzeń tej samej konfiguracji z wieloma ziarnami.

Tabela 5.3: Protokół końcowej serii HPO

Element	Ustawienie
Wersja danych i cel	Numerai v5.3, <code>target_ender_60</code>
Próba i ziarna	10%, 274 627 wierszy, dane: 20260824, model: 20260824 + <i>nr próby</i>
Podział	506 er train, 16 er purge, 52 ery holdout
Późniejszy przedział	88 er, 58 263 wiersze z er 1133-1220, z predykcją Meta Modelu
Funkcja celu	oficjalny <code>numera_i_corr_sharpe</code> na holdoucie
Sampler	Optuna TPE, 20 ukończonych prób startowych, adaptacja od próby 23
Przestrzeń modeli	XGBoost, LightGBM, CatBoost, TabPFN, TabICL
Złożoność próby	jeden model na poziomie potoku, drzewa: 3 lub 5 modeli bazowych i Ridge
Limity	plan: 200 prób lub 11,5 h, 1800 s na próbę, wykonanie: 32 uruchomienia, 27 ukończonych, ok. 1 h 43 min
Implementacja metryk	<code>numera_i-tools==0.6.0</code>

Źródło: opracowanie własne.

5.6 Przestrzeń konfiguracji

Jedna próba wybiera rodzinę modelu, grupy cech, skalowanie, opcjonalną selekcję wariancji, parametry regularizacji, liczbę iteracji i stopień neutralizacji względem cech. Mechanizm kierowania cech łączy zestawy bazowe (`small`, `medium`) z grupami tematycznymi z katalogu Numerai. Liczba wejściowych cech różni się zatem między konfiguracjami.

Dla modeli wzmocniania gradientowego zmieniano między innymi tempo uczenia, złożoność drzew, próbkowanie podzbioru i regularyzację. TabPFN i TabICL działały w profilach pamięciowych ograniczających liczbę przykładów oraz wymiar po redukcji. Ich wyniki opisują zachowanie w tym konkretnym budżecie, a nie ogólną przewagę jednej architektury nad drugą.

5.7 Metryki i reguła selekcji

Główną metryką jest oficjalny CORR Sharpe z równania (2.5) na 52-erowym holdoucie. Dla obu przedziałów raportowane są średni CORR, odchylenie, udział dodatnich er i maksymalne obsunięcie. Na 88-erowym późniejszym przedziale obliczany jest dodatkowo oficjalny MMC Sharpe.

Nie tworzą syntetycznej funkcji łączącej CORR i MMC. Zamiast tego wyróżniono:

1. lidera CORR Sharpe na holdoucie,
2. lidera CORR Sharpe na późniejszym przedziale,
3. lidera MMC Sharpe na późniejszym przedziale,
4. zbiór Pareto względem CORR i MMC na późniejszym przedziale.

Taka reguła zachowuje interpretowalność kompromisu między siłą sygnału i jego wkładem niezależnym od Meta Modelu. Jednocześnie wybór maksimum spośród 27 prób powoduje błąd selekcyjny, więc wartości kandydatów opisują badaną serię, a nie nieobciążone oczekiwanie wyniku przyszłego.¹

5.8 Metody analizy

Dla każdej kompletnej próby zestawiono metryki, czas wykonania, rodzinę modelu i liczbę cech skierowanych do modelu. Zgodność dwóch przedziałów czasowych oceniono korelacją Pearsona oraz korelacją rang Spearmana. Ze względu na małą liczbę konfiguracji i adaptacyjny sposób ich doboru współczynniki te są statystykami opisowymi. Nie raportuje się dla nich testów istotności ani przedziałów ufności. Rodziny modeli porównano za pomocą median, wykresów pudełkowych i wszystkich punktów, zawsze z podaniem liczebności.

Front Pareto wyznaczono przez dominację dwukryterialną: konfiguracja należy do frontu, jeżeli nie istnieje inna próba o co najmniej takim samym CORR Sharpe i MMC Sharpe oraz wyniku ściśle lepszym w co najmniej jednym kryterium. Przebieg HPO analizowano przez maksimum narastające. Fazy rozdzielono według liczby ukończonych prób: ostatnią propozycją startową była próba 22, a pierwszą adaptacyjną próba 23.

Eksploracyjna analiza wrażliwości budżetu obejmuje trzy scenariusze maksimum holdoutowego CORR Sharpe dla 50, 100 i 200 kompletnych prób. Scenariusz empiryczny przelosowuje z powtórzeniami siedem ukończonych wyników fazy adaptacyjnej, bez dopuszczenia wartości spoza ich zakresu. W scenariuszach wygładzonych każda z 200 000 replikacji najpierw bootstrakuje obserwacje i estymuje ich średnią oraz odchylenie standardowe, a maksimum przyszłych losowań wyznacza z lokalnego rozkładu normalnego. Pierwszy scenariusz wygładzony wykorzystuje siedem wyników fazy adaptacyjnej TPE, a drugi 16 wyników LightGBM i CatBoost. Ziarno symulacji wynosi 20260830. Kolejne propozycje TPE nie są niezależne ani wymienne, dlatego raportowany odsetek replikacji z poprawą jest wynikiem warunkowym przy założeniach scenariusza, a nie estymatorem prawdopodobieństwa poprawy. Nie symulowano późniejszego CORR ani MMC.

5.9 Zagrożenia dla trafności

Badanie końcowe obejmuje jedno ziarno doboru danych, po jednym deterministycznym ziarnie modelu dla każdej próby i 27 kompletnych konfiguracji. Nie wykonano powtórzeń konfiguracji z różnymi ziarnami. Łączny dobór 20 konfiguracji startowych i siedmiu adaptacyjnych powoduje nierówne liczebności rodzin, dlatego agregaty mają charakter opisowy, a nie testowy. HPO korzysta z 10% danych uczących, a wyników nie ekstrapoluje się na pełny trening. Bench-

¹Cawley i Talbot, patrz uw. 1; Varma i Simon, patrz uw. 5.

mark v5.2 dokumentuje wykonanie potoku na pełnej skali badanego zbioru, lecz inny cel i wersja danych wykluczają porównanie jakości.

Holdout był wielokrotnie wykorzystywany przez funkcję celu. Późniejszy przedział 88 er nie sterował samplerem, ale służył do porównania prób i wyboru kandydatów. Nie jest więc nie-
tkniętym zbiorem testowym, a maksimum może być optymistycznie obciążone. Oba przedziały reprezentują po jednym zakresie rynkowym. Wdrożenie produkcyjne powinno poprzedzać ponowne uczenie wybranej receptury na pełnych danych oraz monitorowanie wielu kolejnych rund bieżących.

Badanie nie zawiera kontrolowanego modelu referencyjnego ani ablacji komponentów. Benchmark pełnoskalowy używa innej wersji danych i celu, a próby HPO różnią się jednocześnie rodziną modelu, kierowaniem cech, przetwarzaniem wstępnym i neutralizacją. Wyniki dokumentują wykonalność systemu i dostarczają opisowego rankingu w zadanym budżecie, ale nie pozwalają przypisać różnicy jakości pojedynczemu mechanizmowi.

Rozdział 6

Wyniki eksperymentów

Rozdział przedstawia wyniki benchmarku pełnoskalowego oraz analizę końcowej serii HPO. Wszystkie rankingi jakości pochodzą z jednego protokołu v5.3 i zostały wyznaczone za pomocą oficjalnych metryk Numerai.

6.1 Weryfikacja pełnej skali

Benchmark pełnoskalowy objął 2 746 268 wierszy uczących, 780 cech i 574 ery. Potok z dziesięcioma partycjami XGBoost wykonał trening, predykcję dla 3 895 460 wierszy walidacyjnych, ocenę i zapis diagnostyki w 1888,6 s (31,5 min). Zapisano rozwiniętą konfigurację, jej skrót oraz dane diagnostyczne przebiegu. Rezultat dokumentuje działanie tego samego systemu na pełnym zbiorze, nie jest porównaniem jakości ani identycznej konfiguracji z końcową serią HPO.

Tabela 6.1: Wynik operacyjny benchmarku pełnoskalowego

Wielkość	Wartość
Wiersze train / validation	2 746 268 / 3 895 460
Liczba cech / er train	780 / 574
Modele składowe	10 × XGBoost
Czas całkowity	1888,6 s (31,5 min)

Źródło: opracowanie własne.

6.2 Kompletność końcowej serii HPO

Zrealizowana seria trwała około 1 h 43 min i objęła 32 prób w ramach maksymalnego budżetu 200 prób lub 11,5 h. Kompletny wynik uzyskano dla 27 konfiguracji (84,4% całej puli) i tylko one weszły do dalszej analizy. Ich łączny czas modelowy wyniósł 1,44 h, a mediana czasu próby 127,2 s. Nierówne liczebności rodzin ograniczają porównanie do charakteru opisowego.

6.3 Rozkład oficjalnych metryk

Tabela 6.2 syntetyzuje wszystkie kompletne konfiguracje. Na holdoutcie dodatni CORR Sharpe uzyskało 25 z 27 prób. Na późniejszym przedziale selekcyjnym dodatni CORR Sharpe osiągnęły 24 próby, natomiast dodatni MMC Sharpe 13 prób. Różnica pokazuje, że sama korelacja z celem nie gwarantuje unikalności sygnału względem Meta Modelu.

Tabela 6.2: Podsumowanie oficjalnych metryk dla 27 kompletnych prób

Metryka	Średnia	Mediana	Wynik dodatni
CORR Sharpe, holdout (52 ery)	0,479	0,553	25/27
CORR Sharpe, późniejszy (88 er)	0,128	0,128	24/27
MMC Sharpe, późniejszy (88 er)	0,0247	−0,0098	13/27


Źródło: opracowanie własne.

6.4 Rodziny modeli w ustalonym budżecie

Nazwa rodziny oznacza bazowy estymator użyty wewnątrz `EraEnsembleModel`, a nie pojedynczy model. Wśród kompletnych prób CatBoost wystąpił 10 razy (dziewięć zespołów po 5 modeli bazowych i jeden po 3), LightGBM 6 razy (cztery zespoły po 5 i dwa po 3), a XGBoost 8 razy (trzy zespoły po 5 i pięć po 3). Każdy taki zespół zawierał ponadto meta-model Ridge. TabPFN wystąpił dwukrotnie, a TabICL raz.

Najwyższe mediany CORR Sharpe na holdoutcie uzyskały CatBoost (0,659, $n = 10$) i LightGBM (0,655, $n = 6$). Mediana XGBoost wyniosła 0,273 ($n = 8$), TabICL 0,300 ($n = 1$), a TabPFN 0,015 ($n = 2$). Wszystkie obserwacje i rozrzut przedstawia rysunek 6.1.

Rysunek 6.1: Oficjalny CORR Sharpe na holdoucie według rodziny modelu. Punkty oznaczają kompletne próby, a licznosci podano nad grupami.




Źródło: opracowanie własne.

Na późniejszym przedziale mediana LightGBM wyniosła 0,280, CatBoost 0,133, XGBoost 0,036, TabPFN 0,108, a TabICL 0,088. Wynik jest opisem badanego budżetu, nie rankingiem architektur w ogólności: TPE przydzielił rodzinom różne liczby prób, a modele typu foundation korzystały z limitów liczby przykładów i redukcji wymiaru.

6.5 Przebieg optymalizacji

Faza inicjalna trwała do uzyskania 20 kompletnych konfiguracji. Ostatnią propozycją startową była próba 22, a pierwszą adaptacyjną propozycją TPE próba 23. Lider holdoutu pojawił się w próbie 11. Jeszcze w fazie startowej próba 22 podniosła maksimum CORR Sharpe na późniejszym przedziale z 0,402 do 0,425. Siedem kompletnych prób adaptacyjnych (23-27, 29 i 30) nie poprawiło żadnego z tych maksimum (rysunek 6.2).

Rysunek 6.2: Wyniki prób i maksimum narastające dla holdout oraz późniejszego przedziału. Linia przerywana oddziela fazę inicjalną od adaptacji TPE.




Źródło: opracowanie własne.

W zrealizowanym fragmencie fazy adaptacyjnej nie pojawił się nowy lider. Obserwacja ta nie dowodzi nieskuteczności TPE: faza obejmowała tylko siedem kompletnych prób, a nie wykonano równoległego eksperymentu kontrolnego z losowym próbkowaniem o tym samym budżecie.

6.6 Scenariuszowa ekstrapolacja dłuższego HPO

W celu oceny możliwego efektu dłuższego uruchomienia wykonano symulację scenariuszową wyłącznie dla maksimum CORR Sharpe na holdoutcie wykorzystanym w badaniu. Nie jest to prognoza jakości rynkowej. Scenariusz empiryczny losuje z siedmiu zaobserwowanych wyników fazy adaptacyjnej TPE i nie tworzy niewidzianego ogona. Pierwszy scenariusz wygładzony estymuje średnią i odchylenie przez bootstrap tych samych siedmiu wyników, a następnie losuje z rozkładu normalnego. Drugi scenariusz wygładzony stosuje tę samą procedurę do 16 obserwacji LightGBM i CatBoost, czyli rodzin, które w zrealizowanej serii miały najwyższe mediany. Dla każdego budżetu wykonano 200 000 replikacji z ziarnem 20260830. W każdej replikacji wynik końcowy jest większą z wartości obecnego lidera 1,0443 i maksimum przyszłych losowań.

Rysunek 6.3: Scenariuszowa ekstrapolacja najlepszego CORR Sharpe na holdoutcie i odsetka replikacji poprawiających obecnego lidera. Pasma oznaczają kwantyle 5-95% między replikacjami, a nie przedziały ufności jakości w rundach bieżących.



Źródło: opracowanie własne.

Tabela 6.3: Scenariusze maksimum CORR Sharpe na holdoucie po zwiększeniu łącznej liczby kompletnych prób

Scenariusz	Budżet	Średnia	Mediana	Kwantyle 5-95%	Replikacje z poprawą
TPE, 7 prób (wygładzony)	50	1,0481	1,0443	1,0443-1,0676	8,0%
TPE, 7 prób (wygładzony)	100	1,0542	1,0443	1,0443-1,1151	19,9%
TPE, 7 prób (wygładzony)	200	1,0635	1,0443	1,0443-1,1488	33,5%
Drzewa, 16 prób (wygładzony)	50	1,0634	1,0443	1,0443-1,1700	24,1%
Drzewa, 16 prób (wygładzony)	100	1,0886	1,0443	1,0443-1,2398	47,0%
Drzewa, 16 prób (wygładzony)	200	1,1156	1,0837	1,0443-1,2889	63,5%


Źródło: opracowanie własne.

Empiryczne przelosowanie siedmiu wyników TPE daje dla każdego budżetu maksimum 1,0443 i zerowy odsetek replikacji z poprawą, ponieważ najlepszy zaobserwowany wynik tej fazy jest niższy od dotychczasowego lidera. Dopiero założenie o ciągłym, niewidzianym ogonie rozkładu dopuszcza poprawę. Duża różnica między scenariuszami oraz szerokie górne granice pokazują, że wynik jest bardzo wrażliwy na założenia przy zaledwie siedmiu próbach adaptacyjnych. Nie ekstrapolowano późniejszego CORR ani MMC, ponieważ nie były funkcją celu HPO i służyły już do selekcji kandydatów.

6.7 Transfer między przedziałami czasowymi

Korelacja Pearsona między CORR Sharpe na holdoucie i późniejszym przedziale wyniosła $r = 0,360$, a korelacja rang Spearmana $\rho = 0,377$. Związek jest dodatni, lecz umiarkowany: wysoka pozycja na 52-erowym holdoucie tylko częściowo współwystępuje z dobrym wynikiem później i nie zachowuje rankingu konfiguracji (rysunek 6.4).

Rysunek 6.4: Zgodność CORR Sharpe między holdoutem i późniejszym przedziałem dla 27 kompletnych konfiguracji.



Źródło: opracowanie własne.

Próba 11 maksymalizuje wynik na holdoucie, lecz na późniejszym przedziale ustępuje próbom 22, 4 i 10. Uzasadnia to zastosowanie dwustopniowej selekcji w tym badaniu: holdout steruje HPO, natomiast późniejszy przedział dostarcza dodatkowej informacji o zachowaniu konfiguracji w kolejnym okresie. Ponieważ wykorzystano go do wyboru kandydatów, nie pełni on funkcji niezależnego zbioru testowego.

6.8 Kandydaci końcowi

Tabela 6.4 zestawia pięć reprezentatywnych konfiguracji. Próba 11 jest liderem holdoutu, próba 22 liderem CORR na późniejszym przedziale, a próba 4 liderem MMC. Próby 10 i 8 pokazują mocne alternatywy z rodzin LightGBM i XGBoost.


W przestrzeni CORR-MMC późniejszego przedziału tylko próby 22 i 4 nie są zdominowane (rysunek 6.5). Próba 22 maksymalizuje jakość sygnału, a próba 4 jego unikalność. Nie istnieje więc jeden zwycięzca niezależny od celu wdrożeniowego.

Tabela 6.4: Oficjalne metryki końcowych kandydatów. HO - holdout, PP - późniejszy przedział

Próba	Model	HO CORR		PP CORR		PP MMC	
		średnia	Sharpe	średnia	Sharpe	średnia	Sharpe
22	LightGBM	0,03032	0,7149	0,01679	0,4247	0,00802	0,2467
4	CatBoost	0,02161	0,4779	0,01483	0,4024	0,01031	0,3063
10	LightGBM	0,02743	0,7191	0,01450	0,3372	0,00716	0,1871
11	LightGBM	0,03742	1,0443	0,01038	0,2880	0,00310	0,1023
8	XGBoost	0,02047	0,5072	0,00705	0,1971	0,00142	0,0450

Źródło: opracowanie własne.

Rysunek 6.5: Front Pareto na późniejszym przedziale. Okręgi wyróżniają próby niezdominowane względem CORR Sharpe i MMC Sharpe.



Źródło: opracowanie własne.

Do treningu nastawionego na stabilny CORR wybrano próbę 22. Jest to zespół pięciu modeli bazowych LightGBM i meta-modelu Ridge, z RobustScalerem i grupową selekcją wariancji. Konfiguracja próby łączy 989 unikalnych cech z grup `medium`, `agility` i `midnight`, a po selekcji do LightGBM trafia 876 kolumn. Model wykorzystuje 200 rund, tempo uczenia 0,0200, 31 liści i neutralizację cech 0,2373. Jej CORR Sharpe wynosi 0,7149 na holdoucie i 0,4247 na późniejszym przedziale, przy dodatnim MMC Sharpe 0,2467.

Próba 4 jest alternatywą nastawioną na MMC. Wykorzystuje pięć modeli bazowych CatBoost i meta-model Ridge, StandardScaler, 970 cech z grup `small`, `agility`, `constitution`, `dexterity`, `faith` oraz `intelligence`, 2000 rund, głębokość 5, tempo uczenia 0,0314 i neutralizację 0,4947. Osiąga CORR Sharpe 0,4024 oraz MMC Sharpe 0,3063 na późniejszym przedziale. Próba 11 uzyskała najwyższy wynik na holdoucie: CORR Sharpe 1,0443, średni CORR 0,0374, maksymalne obsunięcie 0,0396 i 84,6% dodatnich er.

Rozdział 7

Dyskusja i zakończenie

7.1 Realizacja celu pracy

Głównym celem pracy było stworzenie konfigurowalnego środowiska AutoML dla finansowych potoków predykcyjnych w turnieju Numerai. Cel zrealizowano na trzech poziomach: projektu architektury, implementacji oraz weryfikacji empirycznej. AlphaPulse łączy pobieranie danych, walidowany schemat YAML, kierowanie cech do modeli, optymalizację hiperparametrów, ocenę z zachowaniem porządku czasowego, zapis proveniencji i eksport funkcji predykcyjnej. Benchmark pełnoskalowy wykazał, że kompletny przepływ może zostać wykonany na całym badanym zbiorze. Seria HPO na danych v5.3 pokazała natomiast, że system umożliwia porównywanie różnych konfiguracji według jednego protokołu uwzględniającego wymagania domenowe.

Wartość rozwiązania nie sprowadza się do pojedynczego estymatora. Głównym rezultatem inżynierskim jest kontrolowane środowisko eksperymentalne: konfiguracja opisuje zamierzony przebieg eksperymentu, warstwa wykonawcza stosuje ustalony podział i sposób obliczania metryk, a baza prób wiąże wyniki z wersją kodu, danymi i ziarnem losowym. Takie rozdzielanie odpowiada założeniom współczesnego AutoML i uzupełnia je o wymagania właściwe dla danych finansowych.¹

7.2 Interpretacja wyników modelowych

Najwyższe mediany CORR Sharpe na holdoutcie uzyskały konfiguracje z bazowymi estymatorami LightGBM i CatBoost. W każdej próbie z modelem drzewiastym estymator był jednak opakowany w EraEnsembleModel: trzy lub pięć modeli bazowych trenowano na rozłącznych partycjach er, a ich predykcje łączył model Ridge uczony na wewnętrznym przedziale walidacyjnym. Wynik dotyczy zatem rodzin bazowych w tej konkretnej konstrukcji zespołowej, a nie pojedynczych estymatorów. Jest on zgodny z badaniami wskazującymi wzmacnianie gradientowe jako silną klasę metod dla danych tabelarycznych.² Nie dowodzi jednak uniwersalnej przewagi tych algorytmów: poszczególne rodziny miały różne liczby prób, a modele typu foundation działały z bardziej restrykcyjnymi limitami pamięci.

Dodatnia, ale umiarkowana korelacja wyników między holdoutem a późniejszym przedziałem wskazuje, że jakość konfiguracji nie przenosi się w czasie w sposób jednoznaczny. Separacja typu purge ogranicza przeciek wynikający z nakładania się horyzontu celu, lecz nie usuwa niestacjonarności rynku.³ Późniejszy przedział obejmujący 88 er nie wpływał na decyzje sam-

¹He, Zhao i Chu, patrz uw. 3; Akiba i in., patrz uw. 10; Liaw i in., patrz uw. 10.

²Ke i in., patrz uw. 11; Prokhorenkova i in., patrz uw. 11; Grinsztajn, Oyallon i Varoquaux, patrz uw. 11.

³López de Prado, patrz uw. 6; Bergmeir, Hyndman i Koo, patrz uw. 6.

plera, ale posłużył do oceny transferu i wyboru prób 22 i 4. Nie jest więc niezależnym zbiorem testowym.⁴

Próby 22 i 4 tworzą front Pareto na późniejszym przedziale. Próba 22 uzyskała najwyższy CORR Sharpe przy dodatnim MMC Sharpe, natomiast próba 4 osiągnęła najwyższy MMC Sharpe przy nieco niższym CORR Sharpe. Reprezentują dwa profile: pierwszy akcentuje zgodność predykcji z celem, a drugi ich wkład niezależny od Meta Modelu.⁵ Obie próby należały jeszcze do losowej fazy startowej TPE. Pierwszą próbą adaptacyjną była próba 23. Wyników prób 22 i 4 nie można zatem przypisywać adaptacyjnemu działaniu samplera.

7.3 Odpowiedzi na pytania eksperymentalne

1. **Wykonalność na pełnym zbiorze i zapis przebiegu** Potok przetworzył 2,75 mln wierszy uczących i 3,90 mln wierszy walidacyjnych w 31,5 min. Uruchomienie zapisało konfigurację, jej skrót, metryki i artefakty. Końcowa seria HPO utrzymywała dodatkowo skróty danych i drzewa źródeł.
2. **Rodziny modeli** W zrealizowanym budżecie najwyższe mediany na holdoutcie uzyskały zespoły erowe z bazowymi modelami CatBoost i LightGBM. Porównanie ma charakter opisowy, ponieważ liczba prób dla rodzin była różna, a konfiguracje nie tworzyły kontrolowanej ablacji.
3. **Transfer i kompromis CORR-MMC** Zgodność wyników na dwóch przedziałach była dodatnia, ale umiarkowana. Próby 22 i 4 utworzyły front Pareto i reprezentują odpowiednio profil CORR oraz MMC.
4. **Koszt i kompletność procesu** Uruchomiono 32 próby, z których 27 zakończyło się kompletnym wynikiem. Mediana czasu kompletnej próby wyniosła 127,2 s. Zrealizowany zakres był mniejszy od górnego limitu 200 prób lub 11,5 godziny, dlatego wyniki opisują faktycznie wykorzystany budżet.
5. **Wrażliwość na hipotetyczny budżet** W scenariuszu wygładzonym opartym na siedmiu próbach TPE 33,5% replikacji dla 200 kompletnych prób poprawiało obecnego lidera, a w scenariuszu opartym na 16 próbach LightGBM i CatBoost odsetek ten wyniósł 63,5%. Rozpiętość potwierdza dominujący wpływ założeń przy zaledwie siedmiu obserwacjach adaptacyjnych. Wartości nie są estymowanymi prawdopodobieństwami ani prognozą jakości w rundach bieżących.

Odpowiedzi wynikają z pomiarów oraz analiz scenariuszowych opartych na zapisanych artefaktach. Nie można na ich podstawie wnioskować o skróceniu czasu pracy człowieka, o przewadze AutoResearch nad TPE ani o przewadze TPE nad próbkowaniem losowym.

⁴Cawley i Talbot, patrz uw. 1; Varma i Simon, patrz uw. 5.

⁵Numerai, *Correlation (CORR)* - Numerai Tournament Documentation, patrz uw. 3; Numerai, *Meta Model Contribution (MMC)* - Numerai Tournament Documentation, patrz uw. 4.

7.4 Znaczenie inżynierskie

Projekt pokazuje, że wymagania domenowe można odwzorować w kontraktach oprogramowania. Kolumna `ery` nie jest traktowana jak zwykła cecha, lecz steruje podziałem danych. Horyzont celu wyznacza wymaganą separację czasową, oficjalne metryki są częścią ewaluatora, a funkcja `predict.pkl` dla Model Upload jest sprawdzana lokalnie w odizolowanym podprocesie. Test syntetyczny potwierdza techniczną poprawność artefaktu przed weryfikacją w oficjalnym środowisku Numerai. Ryzyko metodologiczne jest dzięki temu ograniczane przez architekturę systemu, a nie wyłącznie przez dyscyplinę osoby prowadzącej eksperyment.

Istotną rolę pełni warstwa artefaktów. Plik `protocol.json` dokumentuje dane wejściowe i reguły badania, `trials.db` przechowuje stan prób, a W&B umożliwia porównywanie przebiegów i diagnostyk. Eksport `predict.pkl` łączy etap eksperymentalny z inferencją na danych bieżącej rundy.

7.5 Ograniczenia

Seria obejmuje 10% danych, jedno ziarno próbkowania i 27 kompletnych konfiguracji bez powtórzeń wieloziarnowych. Nierówne liczebności rodzin oraz krótka faza adaptacyjna oznaczają, że porównania są opisowe i nie pozwalają wyznaczyć niepewności rankingu.

Holdout był funkcją celu, a późniejszy przedział służył także do wyboru kandydatów, więc żaden z nich nie stanowi niezależnego testu końcowego. Kandydaci wymagają zatem ponownej oceny na nowych okresach.

Ekstrapolacja budżetu jest analizą scenariuszową opartą na małej liczbie prób i nie uwzględnia pełnego treningu ani jakości w rundach bieżących. Benchmark pełnoskalowy korzysta z innej wersji danych i celu niż HPO, a brak kontrolowanego modelu referencyjnego i ablacji nie pozwala przypisać różnic jakości pojedynczym elementom konfiguracji. Wyników nie należy interpretować jako prognozy stopy zwrotu ani argumentu za stakingiem.

7.6 Rekomendacja wdrożeniowa i dalszy rozwój

Próby 22 i 4 są kandydatami do ponownego, kontrolowanego treningu. Oba profile wymagają oceny dla wielu ziaren i na kroczących oknach. Dopiero wyniki kolejnych, niewykorzystanych do selekcji rund mogą uzasadnić wdrożenie lub staking.

Dalsze badania powinny objąć kontrolowany model referencyjny, ablacje kierowania cech, selekcji wariancji, liczby partycji EraEnsemble i neutralizacji oraz pełne wykorzystanie z góry ustalonego budżetu. AutoResearch należy porównać z TPE przy tej samej przestrzeni i liczbie ocen. Rozwój produkcyjny może ponadto objąć harmonogram ponownego treningu, automatyczną walidację artefaktu i monitorowanie zmian metryk dla kolejnych er. Jeżeli HPO zostanie wznowione, wyniki należy raportować w ustalonych z góry punktach kontrolnych (np. 50, 100

i 200 kompletnych prób) i porównać je z przedstawionymi scenariuszami, zamiast traktować symulację jako oczekiwany wynik.

7.7 Wnioski końcowe

AlphaPulse realizuje kompletny cykl eksperymentalny dla Numerai: od danych i deklaratywnej konfiguracji, przez walidację czasową i optymalizację hiperparametrów, po diagnostykę i eksport. W przeprowadzonej serii system obsłużył trening pełnoskalowy oraz pozwolił wyłonić dwa niezdominowane profile. Próba 22 osiągnęła CORR Sharpe 0,4247 i MMC Sharpe 0,2467 na późniejszym przedziale, natomiast próba 4 osiągnęła MMC Sharpe 0,3063. Są to wyniki opisowe, obciążone ograniczeniami selekcji. Uzasadniają dalszą walidację, ale nie stanowią potwierdzenia jakości produkcyjnej.

Najważniejszym wkładem pracy jest połączenie metodyki dla danych finansowych z inżynierią eksperymentów oraz ujawnienie granic tej implementacji. Rezultatem nie jest pojedynczy wynik liczbowy, lecz system umożliwiający kontrolowane porównywanie konfiguracji i przejście od hipotezy do przenośnego artefaktu predykcyjnego. Jego gotowość produkcyjna zależy od ponownej oceny kandydatów na nowych okresach i stałego monitorowania jakości.

Wykaz tabel

5.1	Podsumowanie analizy zbioru v5.3	22
5.2	Serie wykorzystane w badaniu	24
5.3	Protokół końcowej serii HPO	26
6.1	Wynik benchmarku pełnoskalowego	29
6.2	Podsumowanie oficjalnych metryk	30
6.3	Wyniki ekstrapolacji HPO	34
6.4	Końcowi kandydaci	36

Wykaz rysunków

3.1	Architektura logiczna AlphaPulse	14
5.1	Analiza eksploracyjna zbioru v5.3	23
5.2	Podział czasowy badania końcowego	25
6.1	Wyniki według rodziny modelu	31
6.2	Przebieg końcowej serii HPO	32
6.3	Ekstrapolacja budżetu HPO	33
6.4	Holdout a późniejszy przedział	35
6.5	Front Pareto CORR-MMC	36

Bibliografia

- Akiba, T. i in. “Optuna: A Next-generation Hyperparameter Optimization Framework”. W: *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2019.
- Bailey, D. H. i in. “The Probability of Backtest Overfitting”. W: *Journal of Computational Finance* 20.4 (2017), 39-69.
- Bergmeir, C., R. J. Hyndman i B. Koo. “A Note on the Validity of Cross-Validation for Evaluating Autoregressive Time Series Prediction”. W: *Computational Statistics and Data Analysis* 120 (2018), 70-83.
- Bergstra, J. i Y. Bengio. “Random Search for Hyper-Parameter Optimization”. W: *Journal of Machine Learning Research* 13 (2012), 281-305.
- Cawley, G. C. i N. L. C. Talbot. “On Over-Fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation”. W: *Journal of Machine Learning Research* 11 (2010), 2079-2107.
- Chen, T. i C. Guestrin. “XGBoost: A Scalable Tree Boosting System”. W: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016.
- Feurer, M. i in. “Efficient and Robust Automated Machine Learning”. W: *Advances in Neural Information Processing Systems*. T. 28. 2015.
- Grinsztajn, L., E. Oyallon i G. Varoquaux. “Why Do Tree-Based Models Still Outperform Deep Learning on Typical Tabular Data?” W: *Advances in Neural Information Processing Systems*. T. 35. 2022.
- He, X., K. Zhao i X. Chu. “AutoML: A Survey of the State-of-the-Art”. W: *Knowledge-Based Systems* 212 (2021).
- Hollmann, N. i in. “Accurate Predictions on Small Data with a Tabular Foundation Model”. W: *Nature* 637 (2025), 319-326.
- Ke, G. i in. “LightGBM: A Highly Efficient Gradient Boosting Decision Tree”. W: *Advances in Neural Information Processing Systems*. 2017.
- Kotthoff, L. i in. “Auto-WEKA 2.0: Automatic Model Selection and Hyperparameter Optimization in WEKA”. W: *Journal of Machine Learning Research* 18.25 (2017), 1-5.
- Liaw, R. i in. “Tune: A Research Platform for Distributed Model Selection and Training”. W: *arXiv preprint arXiv:1807.05118* (2018).
- López de Prado, M. *Advances in Financial Machine Learning*. Wiley, 2018.
- Numerai. *Correlation (CORR) - Numerai Tournament Documentation*. URL: <https://docs.numer.ai/numerai-tournament/scoring/correlation-corr> (term. wiz. 23.08.2026).

- Numerai. *Meta Model Contribution (MMC) - Numerai Tournament Documentation*. URL: <https://docs.numer.ai/numerai-tournament/scoring/meta-model-contribution-mmcc> (term. wiz. 23.08.2026).
- Numerai. *Model Uploads - Numerai Tournament Documentation*. URL: <https://docs.numer.ai/numerai-tournament/submissions/model-uploads> (term. wiz. 30.08.2026).
- Numerai. *numerai-tools 0.6.0*. Python Package Index. 10 czer. 2026. URL: <https://pypi.org/project/numerai-tools/0.6.0/> (term. wiz. 23.08.2026).
- Numerai. *Scoring - Numerai Tournament Documentation*. URL: <https://docs.numer.ai/numerai-tournament/scoring/> (term. wiz. 23.08.2026).
- Numerai. *Staking - Numerai Tournament Documentation*. URL: <https://docs.numer.ai/numerai-tournament/staking> (term. wiz. 23.08.2026).
- Numerai. *Submissions - Numerai Tournament Documentation*. URL: <https://docs.numer.ai/numerai-tournament/submissions> (term. wiz. 30.08.2026).
- Prokhorenkova, L. i in. “CatBoost: Unbiased Boosting with Categorical Features”. W: *Advances in Neural Information Processing Systems*. 2018.
- Qu, J. i in. “TabICL: A Tabular Foundation Model for In-Context Learning on Large Data”. W: *Proceedings of the 42nd International Conference on Machine Learning*. 2025. arXiv: 2502.05564.
- Sugiyama, M., M. Krauledat i K.-R. Müller. “Covariate Shift Adaptation by Importance Weighted Cross Validation”. W: *Journal of Machine Learning Research* 8 (2007), 985-1005.
- Varma, S. i R. Simon. “Bias in Error Estimation When Using Cross-Validation for Model Selection”. W: *BMC Bioinformatics* 7.91 (2006).
- Wolpert, D. H. “Stacked Generalization”. W: *Neural Networks* 5.2 (1992), 241-259.